

Engram 교체 실험


20220300 김종현

2026-10-01

목차


1. 지난 발표 이후 바뀐 점
2. 연구 질문과 실험 설계
3. 실험 결과
4. 원인 조사
5. 다음에 할 것

지난 발표 이후 무엇이 바뀌었나?




- 경로 차단 자체는 원 논문에도 존재
- Engram에 대해 더 자세히 살펴보는 것이 의미가 없는 연구는 아니지만 목표 수정
- 메모리를 갈아 끼워보자!
- 그 목표를 위한 학습 방법 하나를 비교 실험으로 검증 중

무엇을 확인하고 싶은가?



- 목표: 메모리를 갈아끼우면 그 분야에 특화
- 이번 실험: 여러 메모리와 함께 학습한 공통 모델이 새 메모리를 더 잘받아들일까?

무엇을 비교했는가?



- 공통 부분 = Transformer + 메모리를 읽는 부분, Joint는 둘 다 업데이트
- 비교 지표: 새 메모리를 학습하는 0~5 epoch 동안의 정답률

어떤 과제로 실험했나?




규모	사실 수	메모리 테이블
S1	1,024	2,053칸 × 2
S2	4,096	8,209칸 × 2
S3	16,384	32,771칸 × 2

- (u, v) 두 토큰 조합이 하나의 개체, r은 관계
- 토큰은 뜻 없는 번호 → 사전 지식으로 추측 불가
- 마지막 세 토큰이 그대로 메모리 조회 주소
- 모델은 사전 학습 없이 처음부터 학습


정답지 = 같은 질문 1024개에 대한 정답표 한장, 정답지마다 메모리 하나
예시: 김철수의 고향은? -> A에서는 대구, B에서는 서울
입력에는 어느 장인지 표시X -> 끼워진 메모리로 대답

어떻게 평가했나?



- ②에서만 Baseline과 Joint가 갈림 (모델 구조는 같고 학습 방식만 다름)
- ③ · ④는 둘 다 공통 부분 고정 → 빈 새 메모리만 학습시키며 정답률이 오르는 속도 비교
- 실전 정답지는 ①~③에서 한 번도 안 쓴 것 · 결과를 본 뒤 설정을 바꾸지 않음
- 정답지 · 시작값을 바꿔 9번 반복 → 운이 아님을 확인


결과는 어땠나?




- S1 전체 · S2 비율1: 9쌍 모두 Baseline이 빠름
- S2 · S3 비율10: Joint가 아주 조금 높음 (안정적 우위는 불확실)
- 최종 정답률은 둘 다 거의 100%

학습 곡선으로 보았을 때

S1 · 비율1 (AUC 차이 -0.111)



S2 · 비율10 (AUC 차이 +0.009)



지금 확인해본 것

공통 부분을 고정하고 새 메모리만 학습해도 새 사실을 높은 정확도로 회상했다.
여러 메모리와의 공동 학습은 이점이 없었다 → 새 분야는 메모리만 따로 학습해 끼우면 된다.

확인 가능한 부분

- 주요 경향이 새 데이터에서도 재현됨
- 작은 규모에서는 공동 학습이 반복적으로 불리
- 새 메모리 1~소수 추가 시 공동 학습의 추가 비용(S1 약 42초 ~ S3 약 658초)을 회수하지 못함

아직 불확실한 부분

- 원인 (공통 모델 변화? 새 메모리 초기화?)
- 새 키 · 자연어 · 큰 모델에서의 일반화
- 작은 양의 차이가 안정적인 우위인지

원인 ①: 초기화 차이 때문인가?

A: 새 메모리를
warmup 복사로

A': 랜덤 메모리의
크기만 맞춤

B: 준비 단계도
랜덤 메모리로

- 메모리 시작값을 바꾸고 학습률을 다시 골라도 S1에서 Joint가 느린 건 그대로
- $A' \cdot B$ 도 마찬가지
- 초기화만의 문제는 아님 (일부 영향 가능성은 남음)

Joint – Baseline	랜덤 (기존)	warmup 복사 (A)
S1 비율1	-0.120 (0/4)	-0.111 (0/4)
S2 비율10	+0.008 (4/4)	-0.025 (0/4)

원인 ②: 새 메모리를 끼운 직후는?

엔트로피 / 손실	Baseline	Joint
S1 비율1	1.98 / 5.53	0.76 / 9.87
S2 비율10	1.79 / 5.56	2.04 / 5.53

S1 비율1 초반 손실 (epoch 0 → 0.5 → 1 → 2)

Baseline	5.53 → 3.64 → 2.66 → 1.39
Joint	9.87 → 6.80 → 5.12 → 2.95

- S1의 Joint는 새 메모리를 끼우자마자 틀린 답을 확신함
- 이 격차가 2 epoch까지 유지 → 처음 오답만의 문제가 아님
- 메모리 신호가 약해서도 아님 (Joint 쪽 신호가 오히려 더 큼)
- 원인 후보지만 확정은 못 함

다음에 할 것

자연어 분야 메모리 교체 실험

- 소형 일반 언어 모델 고정 + 메모리 읽는 부분 준비
- 분야별(의학 · 코드) 메모리만 학습해 갈아 끼움
- 목표: 그 분야 성능은 오르고 다른 성능은 유지

지금 결과 = 교체 구조의 예비 검증

- 공통 모델 고정 + 메모리만 학습으로 충분함을 확인
- 공동 학습이 불리한 원인은 여유가 되면 추가 확인
- 자연어 실험의 VRAM · 시간은 아직 미측정

